

ICLR 2027 稿件内部伴读材料

AI4AI4Bio 中文伴读版

协作式证据引导的生物模型改进

这份文件怎么用

它不是对英文稿的逐句替换，而是一份覆盖全部正文和附录的中文导读。先读第 2、8、9、10、18 页即可掌握核心结论，再根据第 13-16 页定位英文稿中的技术细节。

3	5	6	3
生物任务族	主评测端点	因子对照组	预设随机种子

实验状态：全部主实验已完成 | 版本日期：2026-09-22
定位：帮助作者快速理解论证结构、结果边界和答辩要点

01 30 秒读懂这篇论文

先理解论文真正证明了什么，再看实现细节。

要点	中文解释
问题	不同生物实验室持有互补数据，但原始测量往往不能集中共享；已有研究通常只解决本地模型训练，或只让 agent 在可访问数据上改方案。
方法	AI4AI4Bio 把两层过程接起来：内层在数据所属实验室本地训练并聚合更新；外层根据聚合开发集证据提出、执行并筛选可复现的模型设计。
实验	统一测试 DTI、蛋白组学疗效预测、细胞扰动识别三类任务；细胞任务进一步分为单基因、双基因和药物扰动，共五个主端点。
主结果	十实验室完整系统在五个端点中的四个取得三种主配置里的最高分；相对单实验室 direct search 的提升为 +3.87、+16.85、+10.45、+8.10、+6.97 个百分点。
最重要消融	更多实验室参与在五个端点上都带来正增益；但 matched-access 下 loop 与 direct search 的结果全部持平，当前尚未证明迭代反馈本身的独立增益。
结论边界	论文支持的是 expanded participation 带来的 access-enabled system gain；不是新联邦优化算法，不是正式隐私系统，也不是全局 SOTA 或前瞻湿实验验证。

一句话版本

我们提供了一套让多个数据持有方共同训练模型、并用聚合证据共同评估模型设计的统一研究接口；当前实验证明多方参与有用，但尚未证明研究反馈循环本身优于同预算的直接搜索。

02 论文的论证链

正文不是在证明一个万能 agent，而是在验证一个统一协作研究接口。

1. 现实约束

数据分散在实验室，原始响应受隐私、所有权或未公开工作限制。

2. 方法缺口

参数聚合通常固定模型设计；研究 agent 通常要求数据或 evaluator 可直接访问。

3. 我们的接口

数据留在 worker；共享参数更新和聚合开发证据；外层 agent 只修改受约束的可执行配置。

4. 可检验问题

更多参与方是否提高结果？反馈历史是否优于无反馈搜索？选中的改动是否能泛化到 held-out 测试？

5. 证据

三任务族、五端点、六臂因子设计、三 seed、统一预算和同一 scorer。

6. 结论


participation 效果稳定为正；feedback 效果当前为零；search 效果因任务而异。

贡献应当写成“共同接口 + 跨任务执行证据 + 因子化归因”，而不是把四个最好结果包装为五个任务全部 SOTA。

03 研究范式：为什么需要这项工作

Bio-agent research

Accessible-data loop




Iterative model designs

Additional labs require accessible measurements

Collaborative training

Predefined-design updates




Raw data stay local

Research design is fixed in this configuration

AI4AI4Bio

Collaborative research loop



Model + design learning

Evidence guides both parameters and model designs


Complementary configurations, not an exhaustive taxonomy of prior methods.

英文主稿图 1。左：传统 bio-agent 能迭代模型设计，但依赖可访问数据。中：协作训练让原始数据留在本地，但设计固定。右：AI4AI4Bio 同时连接本地参数学习与共享研究循环。

范式	优点	局限
可访问数据上的 bio-agent	能根据实验反馈迭代代码或模型设计	新增实验室通常需把测量交给 agent 或中心环境
固定设计的协作训练	原始数据可留在各 worker，本地更新后聚合	训练的模型结构和研究方案预先固定
AI4AI4Bio	参数更新与模型设计都能利用分布式证据	当前是同机模拟；没有正式隐私保护；反馈增益尚未建立

04 方法：一套核心流程贯穿三个任务

OUTER RESEARCH LOOP | fixed local Qwen2.5-7B



英文主稿图 2。外层 Qwen2.5-7B 提出假设和配置；内层所有任务共享训练、聚合、打分与保留规则，仅预测 adapter 不同。

- 假设：提出一个可检验的配置改动，并声明预期作用。
- 实例化：design ID 被编译为统一十二项候选库中的可执行配置。
- 训练：每个候选从相同 seed 的公共初始化重新开始，训练 100 个协作 round。
- 评估：每五轮由本地开发 worker 返回标量指标；测试集从不进入训练、提案或选择。
- 保留或拒绝：按主指标优先、开发损失破平；失败和负结果保留在历史中。

05 内层训练与外层研究循环分别在做什么

内层：本地参数学习

- 实验室 worker 只读取自己的 train/dev shard，完成一个本地 epoch，再返回参数更新和样本数。
- 协调器按本地训练样本量加权平均。server momentum 为 0 时等价于 sample-weighted FedAvg。
- 所有任务使用 AdamW、梯度裁剪、每轮重置本地 optimizer，并按相同 checkpoint 规则运行。
- 一实验室对照走完全相同代码路径，只是参与集合大小为 1。

外层：证据引导的设计修改

- loop 和 direct 都有六个 proposal slot、同一 Qwen checkpoint、同一候选设计库和同一训练预算。
- direct 只能看到尝试过的配置，不能看到评估结果；loop 能看到先前分数、训练诊断、是否接受或失败。
- 研究模型不查看原始表达谱、相互作用行或测试标签；它只接收配置与聚合标量历史。
- 当前候选空间较小，direct 和 loop 经常覆盖同一组设计，这解释了 feedback 对照全部持平。

术语口径

论文主线称为 collaborative evidence-guided research。FedAvg 只用于精确描述内层聚合实现；论文不声称提出新的联邦优化器，也不把数据本地化等同于隐私保证。

06 实验设计：三个任务族，五个主端点

主表的五行不是五套互不相干的实验，而是三类生物问题的统一协议实例。

任务族	预测问题与数据	模型接口	主指标
DTI	输入化合物与蛋白序列，判断是否互作。BindingDB train/dev 为 50,149/5,604 对；主测试 random split 为 5,505 对。	TAPB 架构；冻结公开 ESM2 蛋白特征，训练药物、融合和分类模块。	AUROC
蛋白组学疗效	输入处理后 6h/24h 蛋白响应和药物 Morgan 特征，预测二元 efficacy；最终角色含 148 个条件。	ProteinTalks-derived efficacy head；不是完整 ppODE 或前向蛋白轨迹模型。	Average Precision
VCC 单基因	从五个候选单基因扰动中识别真实扰动；whole-intervention 60/20/20。	冻结、mask 修正后的 scDEBART 表征，训练 response MLP。	Macro Top-1
Norman 双基因	从五个候选双基因过表达中识别真实组合；70/20/27。	同一 cell adapter 和 scorer。	Macro Top-1
Tahoe 药物	固定细胞背景和剂量，从五个候选药物中识别真实处理；180/60/67。	scDEBART response head 加固定 Morgan 投影条件。	Macro Top-1

统一性在哪里

三任务共享：十客户端划分、训练调度、研究模型、十二项设计库、六次 proposal、选择规则、三个 seed 和 held-out 冻结流程。不同的只有输入表示、预测头和任务指标。

07 主结果：完整系统在五项中的四项最高

主端点	Fixed 1 lab	Direct 1 lab	Ours 10 labs	Ours - Direct
DTI: TAPB random AUROC	82.83	89.89	93.76	+3.87
Proteomics efficacy AP	25.05	20.13	36.99	+16.85
VCC single-gene Top-1	29.94	21.09	31.54	+10.45
Norman double-gene Top-1	25.56	14.15	22.25	+8.10
Tahoe drug Top-1	19.40	15.42	22.39	+6.97

数值为 seeds 42/43/44 的 held-out 均值乘以 100。粗体只表示三种展示配置中最高，不表示统计显著或全球 SOTA。

如何解读

最直观的产品级结论是：允许十个实验室参与的完整系统，相比只使用一个实验室数据的直接优化，在五项上都更高。但这个差异同时包含更多训练数据、更多开发证据和更多计算，不能解释成纯算法优势。

不能回避的例外

Norman 上单实验室 fixed 为 25.56，高于我们的 22.25。论文保留了这个结果；这也是为什么英文稿写 four of five，而不是声称全部任务最优。

08 关键消融：增益来自哪里

主端点	Search: loop - fixed (10 labs)	Feedback: loop - direct (10 labs)	Participation: 10 - 1 labs (loop)
DTI	+1.96	+0.00	+3.87
Proteomics	-0.08	+0.00	+16.85
VCC	+0.00	+0.00	+11.32
Norman	+6.77	+0.00	+8.10
Tahoe	-3.48	+0.00	+6.97

三个列分别回答不同问题

- Search：完整 loop 相对固定配方是否有价值？答案随任务变化，DTI 和 Norman 为正，Tahoe 为负。
- Feedback：给 proposer 看历史评估证据，是否比不看证据的 direct search 更好？当前五项全部为 0.00。
- Participation：保持 loop 机制不变，从一个实验室扩展到十个实验室是否有价值？五项全部为正，这是最稳定的事实。

论文最稳妥的主张

统一接口能让更多实验室的数据和开发证据在不交给研究 LLM 的情况下改善共享模型。当前 bounded loop 提供了可执行、可追踪的设计研究机制，但尚未展示独立的反馈驱动性能收益。

09 三个任务分别说明了什么

DTI：最强的正向算法案例

- 主端点是 TAPB random-split AUROC；我们的十实验室 loop 为 93.76。
- 十实验室 loop 相对十实验室 fixed 提升 1.96 点，说明在这个任务上 bounded design search 有正收益。
- unseen-drug 和 unseen-protein 被强制保留为次要端点，避免只展示随机划分。

蛋白组学：最强的参与增益案例

- 任务是 observed-response efficacy classification，不是从药物预测完整蛋白响应。
- 我们的 AP 为 36.99，相对单实验室 direct 高 16.85 点。
- 十实验室 loop 与 fixed 基本相同，search 效果为 -0.08；主要收益来自参与数据扩展。

细胞扰动：跨 intervention 类型的压力测试

- VCC 单基因、Norman 双基因、Tahoe 药物统一为五选一逆向识别，随机 Top-1 为 20%。
- VCC 和 Tahoe 的完整系统最高；Norman 则由单实验室 fixed 最高。
- 任务是从观察到的响应识别扰动，不等价于标准 forward-expression leaderboard。

10 Harness 到底做了什么，为什么方便审计

阶段	实际产物	审计价值
提出假设	结构化记录假设、预期影响、实验计划和 design ID	能区分事前假设与事后解释
实例化方案	design ID 编译为受约束、可执行配置	减少任意代码漂移，保证不同任务共享同一候选菜单
训练与评估	固定预算的本地训练、checkpoint 选择和聚合开发指标	失败也消耗预算，不会免费重试直到成功
保留或拒绝	主指标优先、loss 破平的 ratchet 规则	避免人工凭测试结果挑模型
传递证据	下一轮只接收配置、分数、训练诊断和接受/失败历史	不向研究 LLM 暴露原始生物响应
冻结测试	先封存配置、checkpoint 和 hash，再开启 held-out scorer	测试结果不能反向影响 proposal

审计不等于防御性写作

审计机制的价值是让“agent 提出了什么、试了什么、为什么接受、哪里失败”都可复核，从而支持可信的性能结论。它是方法能力的一部分，但论文主贡献仍应围绕协作模型改进和实验结果，而不是只强调风险。

11 数据边界：哪些信息被共享，哪些没有

对象	实验室本地	返回协调器	返回研究 LLM
原始训练响应	是	否	否
原始开发响应	是	否	否
模型参数更新	本地产生	是	否
样本数与聚合统计	本地计算	是	仅聚合标量
开发指标与训练诊断	本地计算	聚合	聚合历史
候选配置和研究历史	接收并执行	是	是
held-out 测试结果	独立评估	最终报告	从不反馈

现在可以说什么

原始 response shard 不发送给研究模型；本地 worker 可以通过参数更新和聚合开发证据参与共同模型和设计选择。

现在不能说什么

同机模拟不构成 adversarial isolation；没有 secure aggregation 或 differential privacy；协调基础设施仍参与离线打包和完整性验证。因此不应写成已获得密码学或制度级隐私保证。

12 英文正文逐节导读

部分	在讲什么	读者应带走什么
Abstract	现实问题、双层框架、三任务验证、主要数值和因子消融。	四项最佳，但反馈独立增益未建立。
1 Introduction	数据分散与 agent 研究之间的缺口；定义三项贡献。	贡献是接口、跨任务执行和可归因实验。
2 Related work	定位自动研究、协作训练、FedEx、Helmsman、DrugEvolve 等。	不声称第一个组合两者，也不混用不可比协议。
3 Method	双层优化、FedAvg 实现、Qwen proposal、数据与证据边界。	同一 core，task-specific adapters。
4 Experimental design	三个任务、五端点、六臂、三个 seed、冻结和评分规则。	主表是 access-enabled system comparison；消融负责归因。
5 Results	主表、participation/search/feedback 分解、执行证据与历史支持实验。	participation 稳定为正，feedback 为零。
6 Discussion	解释为什么 loop 未显示额外收益，以及下一步如何验证。	小设计库和六次预算可能让 direct 与 loop 重合。
7 Conclusion	总结方法可行性、实证结论与仍未解决的问题。	不把负结果藏起来。
Reproducibility / Ethics / AI	说明产物、数据许可、隐私边界和 AI 辅助。	所有成绩来自真实 scorer，不是 LLM 估计。

13 附录导读：A 到 J

这些部分主要回答复现、历史比较和 scorer 细节。

附录	内容	为什么存在
A Secondary metrics	完整 seed 级主指标和次要 ranking 指标。	防止主表只给均值或只挑单一指标。
B Infrastructure continuation	中断、重试、恢复和预算记账规则。	证明基础设施故障没有带来额外搜索机会。
C Historical PTPC	早期 ProteinTalks observed-response source-editing 协议。	保留历史证据，但明确不与当前 100-round 主协议混用。
D Search costs and audits	DTI 搜索成本、失败率、校准信息 replay 和审计案例。	展示调用、训练和负结果的完整性。
E Historical DTI architecture search	harness、direct、DrugEvolve 的历史 native-system 比较。	回答与 DrugEvolve 的关系，但不伪装成完全同构复现。
F Full historical DTI metrics	历史十二 epoch 训练的全量指标。	保留所有端点，避免只报最好项。
G/H PTPC supplements	蛋白组学次要指标、成本、案例和来源解释。	支持 efficacy 结论与可解释性边界。
I Cell scorer contracts	Norman archive、逆向识别、sequential/CEX 的精确定义。	防止把不同细胞问题误认为同一 benchmark。
J PTPC diagnostics	标签平衡、固定 head 和历史预测诊断。	区分数据难度、校准问题与研究 loop 的实际贡献。

14 附录导读：K 到 Q

附录	内容	当前稿件中的角色
K Local training and data availability	本地 logistic fitting、中心化等价检查、matched access 和完整 PTPC 对照。	说明 local update 实现正确，但不声称优于同数据中心训练。
L Full-training DTI	冻结 architecture roster 后的完整 DTI 重训、现代 fixed reference 和成本。	把低预算搜索与最终 full fit 区分开。
M Research over fixed DTI predictors	固定预测器上的 program search、TAPB transfer 和互补性解释。	检验 research program 是否能跨预测器迁移。
N Historical studies	早期 cell policy、DTI native package、PTPC matched study。	作为 supporting evidence，不进入当前主表。
O Training-CV-guided feature research	training-only CV、Helmsman adaptation、冻结和成本。	记录另一路反馈研究，包括没有 loop superiority 的结果。
P Strong-start optimization	更强起点下的 DTI/proteomics 研究矩阵与 client scaling。	排除“只因起点太弱才有提升”的部分解释。
Q Trainable cell pilots	已完成的早期 20-round cell pilot。	历史协议；不等于当前 Appendix R 的 100-round 三 seed 结果。

15 附录 R：当前结果的事实底座

Appendix R 是阅读当前主表时最重要的附录。它集中给出：

- 当前 uniform protocol 的版本、完整十二项候选库与六次 proposal 规则。
- 三个 seed 下六个 arm 的全因子 held-out 结果，而不是只给主表三列。
- Search、Feedback、Participation 的完整 effect table 和 seed-level 不确定性。
- DTI random、unseen-drug、unseen-protein 三个 frozen endpoint。
- 所有任务的 AP、AUROC、BCE、MRR、Top-3、cross-entropy 等次要指标。
- 独立重算、hash 绑定、checkpoint seal 和 publication test 结果。

审计项目	数量 / 状态
task-seed studies	15, 全部完成
primary arm-seed cells	90, 全部完成
development audits	15, 全部通过
held-out audits / verifications	30, 全部通过
independently rescored arm-endpoints	135, 全部通过
publication tests	29, 全部通过

为什么主表不放 seed 数

主表只承担“一眼看懂五个端点”的任务。每项都是预设 seeds 42/43/44 的均值；样本标准差、精确 seed 数和不确定性统一放 Appendix R，既不隐瞒，也不破坏主图表的信息层级。

16 可声称、不可声称，以及可能被追问的问题

可以直接声称	需要谨慎表述或不能声称
一个统一接口已在三类生物任务、五个端点上完整执行。	不能说所有任务都达到全球 SOTA；当前比较是稿内三配置和特定 task reference。
十实验室参与相对单实验室 loop 在五项上均有正 held-out 增益。	不能把 10-vs-1 全部归因于优化算法，因为数据、开发证据和计算同时增加。
研究模型不接收原始生物响应，只接收配置和聚合诊断。	不能声称 differential privacy、secure aggregation 或对抗性数据隔离。
所有主实验、三 seed、审计与独立重算已完成。	不能把 retrospective held-out 称为新的 blind confirmation。
DTI 和 Norman 上 search 相对 fixed 有正向结果。	不能说 feedback loop 已经优于 matched-budget direct；五项当前都持平。

高概率追问

问题	建议回答
为什么不用同数据 centralized baseline？	这是当前最重要的补充实验之一。现稿通过等价检查说明聚合目标正确，但没有把所有主任务都做成 same-data centralized 对照。
为什么 loop 没有优于 direct？	候选库只有十二项且预算六次，两者往往尝试相同配置；下一步应扩大可修改空间并设置真正需要连续证据更新的任务。
单实验室为什么固定为 client 0？	这是预先指定的 operational comparator，但可能受 client 代表性影响；更强版本应做 client rotation。
隐私贡献是什么？	当前贡献是 data-local execution boundary 与 information-flow contract，而不是形式化隐私机制。

17 建议阅读顺序与投稿状态

如果只有 15 分钟

- 先看英文稿 Figure 1 和 Figure 2，理解范式差异与统一 pipeline。
- 看正文 Table 1：五个主端点和三种 operational configuration。
- 看正文 Table 2：把 Participation、Search、Feedback 三种效应拆开。
- 读 Discussion：理解为什么 strongest evidence 是 participation，而不是 feedback。
- 需要查数字或复现时直接去 Appendix R；历史方法比较再查 Appendices E、L、M、N、O、P、Q。

项目	当前状态
主实验	完成：3 个任务族、5 个端点、6 个 arm、3 个 seed
主表与关键消融	完成：正文 clean table + effect table
一致性与结果审计	完成：29 tests, 135 个 endpoint 独立重算
英文 PDF	完成：正文 9 页，参考文献从第 10 页开始
仍需作者操作	Overleaf 最终编译；OpenReview 作者信息；AI-use 表单；匿名代码材料

最终判断

稿件已经是完整、可提交、结果可追溯的 ICLR 论文版本。它最有说服力的贡献是跨任务的协作研究接口和稳定 participation 增益；如果有时间继续增强，优先级应是 same-data centralized baseline、client rotation、独立数据集验证，以及能真正区分 feedback 与 direct search 的更大设计空间。

对应英文稿版本：Git commit `ea0a6faf8696d3dc12d90f004bbad22d28300cff`
本伴读版只解释已执行结果，不生成或替代任何实验分数。