

AI4AI4Cell 中文伴读版

协作式证据引导的生物模型改进

核心问题

多个生物实验室拥有互补数据。AI4AI4Cell 让这些数据在本地参与两件事：一是训练共享预测模型，二是为外层研究循环评价和选择下一版可执行设计。

任务族	主端点	实验配置	随机种子
DTI / 蛋白组学 / 细胞扰动	5	六配置对照, 已完成	42 / 43 / 44
蛋白组学 / 3 类细胞扰动	4	同预算训练分配, 已完成	53 / 54 / 55
参与度 / 来源 / 提案预算	见附录 B	按完成记录报告	61 / 62 / 63

对应英文稿：2026-09-22 师姐批注修订版

正文六节 + 附录 A/B；本文件用于快速伴读，不替代英文全文。

附录 B 同源快照 SHA-256：ea19d08df451ffae...

1 论文主线

一句话贡献

我们提出一个统一的协作研究框架：内层通过客户端本地训练更新模型参数，外层通过结构化 proposal、聚合开发证据和持续实验历史改进模型设计。


所谓 two levels 不是同一件事的两种说法，而是两个明确的反馈通道：

- 参数层：每个实验室在本地训练候选模型，协调器聚合更新，得到共享预测器。
- 设计层：每个实验室在本地开发集上评价候选模型，协调器形成 aggregate evidence card，决定保留哪一个设计，并把结果交给下一轮 proposer。

论文的三项贡献

贡献	具体内容
协作研究框架	把 client-local parameter fitting 与 distributed design evaluation 连接起来。
证据引导的 loop 机制	把提案结果打包为可复用历史；把早期学习轨迹用于后续训练分配。这两类作用分别验证。
跨任务实证	共享训练与研究接口，并用匹配预算、参与度、来源和提案预算分析解释效果。

2 三种研究范式



绿色表示本地数据，蓝色表示预测模型，紫色表示研究 harness，橙色表示聚合与门控。K 是参与实验室数，不固定为 10。灰色虚线 harness 表示图中的固定设计配置，并非断言所有已有协作学习工作都没有 agent。集中式面板仅画实际可访问的数据源。

范式	具备的能力	关键差异
Centralized bio-agent	在一份可访问数据上训练、评价并迭代设计	缺少多实验室聚合
Collaborative training	多实验室本地训练并聚合共享模型	可执行设计保持固定
AI4AI4Cell	同时更新共享模型与研究设计	aggregate evidence card 闭合外层循环

3 Harness 外层到底做什么

阶段	输入	输出 / 作用
1. Hypothesize	任务契约、incumbent、历史 evidence cards	提出一个聚焦且可检验的假设
2. Instantiate	结构化 proposal	验证 design_id 并编译为可执行配置
3. Train + evaluate	候选设计、各实验室 train/dev shard	共享 predictor 与聚合开发诊断
4. Retain + remember	候选与 incumbent 的证据	保留较优设计；记录成功、拒绝与失败
5. Next proposal	完整有序研究历史	利用前轮结果形成下一假设；是否有效由独立对照检验

每个 proposal 的固定 JSON 字段

字段	含义
hypothesis	关于一个可编辑因素的明确预测
experiment	要执行的改变以及与 incumbent 的对照
expected_effect	预期指标方向和训练/验证诊断特征
design_id	可被机器解析并编译的候选标识

为什么历史记录重要

下一轮 loop 不只看到当前最好分数，还看到配置、best round、开发 metric/loss、首末训练诊断以及接受/拒绝/失败状态。因此实验历史是研究策略的状态，而不只是日志。

Qwen direct 始终接收固定起始配方及未尝试的 design_id，不接收开发反馈；loop 接收当前保留配置和完整历史。二者的首个提案相同。

4 三个任务如何统一

任务	预测契约	任务参考模型	主指标
DTI	compound + protein → interaction	TAPB + frozen ESM2 protein features	AUROC
Proteomics	observed 6h/24h proteome + drug → efficacy	ProteinTalks-derived efficacy head	AP
VCC	response + 5 single-gene options → identity	corrected scDEBART head	Macro Top-1
Norman	response + 5 double-gene options → identity	corrected scDEBART head	Macro Top-1
Tahoe	response + 5 drug options → identity	scDEBART + Morgan conditioning	Macro Top-1

一致性

五个端点共享同一个 inner trainer、proposal schema、evidence card、研究历史和 finalizer；任务差异只通过 adapter 和 scorer 进入。主实验使用 seeds 42 – 44；反馈隔离实验在四个可完整重训的端点上统一使用 seeds 53 – 55。

六配置因子对照

- 参与度：1 个实验室 vs 10 个实验室。
- 研究模式：fixed recipe vs feedback-free direct search vs feedback-guided loop。
- 主表比较完整系统；因子对照分别估计参与度、设计搜索和提案反馈的差异。

5 主结果

方法 / access	DTI	Protein	VCC	Norman	Tahoe	平均
Task model (1 lab)	82.83 ± 1.22	25.05 ± 4.56	29.94 ± 0.00	25.56 ± 0.00	19.40 ± 0.00	36.55 ± 0.82
Qwen direct (1 lab)	89.89 ± 1.02	20.13 ± 0.07	21.09 ± 4.38	14.15 ± 0.00	15.42 ± 6.21	32.14 ± 2.02
AI4AI4Cell (10 labs)	93.76 ± 1.11	36.99 ± 0.22	31.54 ± 0.08	22.25 ± 0.45	22.39 ± 2.59	41.39 ± 0.60

当前主表为已完成的 3 个 seed：held-out 均值 ± 样本标准差，均乘以 100。标准差反映固定数据划分上的训练／搜索波动，不是标准误或置信区间；总体分先按每个 seed 平均五项指标，再计算标准差。新增重复实验尚未计入。AI4AI4Cell 在五个主端点中的四个最高，五端点描述性均值为 41.39。Norman 的最高值来自单实验室 fixed recipe。

整体结论

完整系统在分子互作、蛋白响应和细胞扰动三类任务上都取得了有竞争力的结果；相对于单实验室 direct optimization，五个端点分别变化 +3.87、+16.85、+10.45、+8.10 和 +6.97 个百分点。

6 证据如何改进训练预算分配

先区分两个实验：主实验的 LLM 提案反馈决定下一次尝试什么设计；本页的固定候选 racing 则决定哪些设计值得继续训练。后者固定十个设计，不依赖 LLM 生成新设计。

端点	均匀分配	证据分配	增益	胜/平/负
Proteomics（留出）	37.47	37.47	+0.00	0/3/0
VCC（留出）	20.01	20.01	+0.00	0/3/0
Norman（留出）	11.48	22.32	+10.84	3/0/0
Tahoe（留出）	20.90	22.89	+1.99	1/2/0

- 均匀分配与证据分配使用相同的十个设计、十个实验室和 160 次开发评估。
- 均匀分配给每个设计 80 轮；证据分配先各训练 20 轮，按当前得分及上升趋势选出六个设计，从共同初始化重新训练 100 轮；两者总计都是 800 个全客户端训练轮。
- 12 个新执行的留出 task-seed 对比为 4 胜、8 平、0 负。Norman 平均提升 10.84 点，95% CI 为 [4.54, 17.73]；Tahoe 平均提升 1.99 点，区间跨零。
- DTI 仅有已有开发轨迹回放：均匀分配 525、证据分配 520 个 candidate-round，开发 AUROC 相差 +0.39 点（2 胜、1 平），单列于附录 A。

已经得到的机制结论

早期证据可以改善训练预算的分配，Norman 上三个种子均受益。它不等于 LLM 提案历史已经带来独立的最终分数增益：原六槽位主实验的 direct 与 loop 选中了相同终点；更大预算的提案研究见下一部分。

7 敏感性：实验室数与数据来源

这两组实验使用默认配方，不替换主表的搜索协议。参与度实验把原始前 K 个客户端加入训练，数据量随 K 增加；固定全池实验把全部数据合并成 K 个训练组，保持原始十个开发面板等权评价。

固定全池，默认配方	K=1	K=2	K=5	K=10
PTPC	34.59 ± 5.66	37.36 ± 1.89	39.19 ± 0.43	37.54 ± 0.27
VCC	29.49 ± 0.00	28.80 ± 0.20	31.06 ± 0.22	31.48 ± 0.16
Norman	49.63 ± 4.20	19.56 ± 0.20	26.12 ± 0.11	15.48 ± 0.00
Tahoe	22.39 ± 0.00	21.39 ± 0.86	20.40 ± 0.86	26.37 ± 0.86

Norman 全池数据放入一个客户端时为 49.63，拆成十个客户端时为 15.48。这里的 K=1 使用全部目标训练数据，不是主表只有一份数据的单实验室基线。分组同时改变局部优化步骤及细胞任务的 contrastive negative pool，所以 K 的效果并不单调。

异源更新是否有用？

VCC 来源设置	Top-1	差值	配对 95% CI
仅目标数据	29.49	+0.00	[0.00, 0.00]
+ Replogle	27.12	-2.37	[-10.09, 4.26]
+ Nadig	26.94	-2.55	[-11.45, 5.10]
+ Jiang	33.07	+3.58	[-2.11, 9.51]
+ 全部三项研究	27.33	-2.15	[-12.12, 6.09]

Jiang 的三种子点估计提高 3.58 点，但按目标扰动重采样的区间跨零；全部来源同时加入反而下降。VCC 的三个来源属于独立研究，这组结果强调来源兼容性，而非来源越多越好。

蛋白组：目标全池 AP 为 34.59，加入全部 mtPTDS 细胞背景后为 35.47。这些来源是同一研究中的三个背景，不是三个独立研究。全部来源组合的差值 95% CI 为 [-2.44, 3.99]。

完整 More-data 与 Fixed-pool 对照、每个来源、样本标准差与不确定性见英文附录 B；缺失的 DTI 评价保留 N/A。

8 提案预算、执行可靠性与完成状态

两后端使用相同 36 配置空间与 24 个提案槽位；槽位失败也计入预算。每个有效候选从共同初始化训练 100 轮。以下只纳入完整跑完 24 槽位并已验证的轨迹；一条 job 同时包含 direct 与 loop。

任务 / proposer	完成	Direct@6 / Loop@6	Direct@24 / Loop@24	有效提案 D / L
DTI / Qwen	0/3	N/A / N/A	N/A / N/A	N/A
DTI / Luna	0/3	N/A / N/A	N/A / N/A	N/A
PTPC / Qwen	1/3	37.27 / 37.27	37.27 / 37.27	19/24 / 14/24
PTPC / Luna	1/3	37.27 / 37.27	37.27 / 37.27	24/24 / 24/24
VCC / Qwen	1/3	31.50 / 31.50	19.61 / 19.61	11/24 / 16/24
VCC / Luna	1/3	16.94 / 16.94	20.23 / 20.01	24/24 / 24/24
Norman / Qwen	1/3	22.30 / 22.30	22.30 / 22.30	15/24 / 12/24
Norman / Luna	1/3	35.48 / 23.11	23.11 / 23.11	24/24 / 24/24
Tahoe / Qwen	1/3	26.87 / 26.87	13.43 / 13.43	14/24 / 15/24
Tahoe / Luna	1/3	13.43 / 26.87	13.43 / 13.43	24/24 / 24/24

Norman seed 61：Luna 使用反馈时在第 4 槽达到共同开发目标，direct 在第 22 槽才达到；但 24 槽位测试终点均为 23.11。Tahoe/Luna 则是 direct 更早达到共同目标（5 对 13 槽）。全部完整 job 的最终测试对照为 loop 0 胜、7 平、1 负；这是描述计数，不是独立显著性检验。搜索更快、开发曲线变平和最终测试增益应分别讨论。

已完成轨迹的有效提案：Qwen 116/192 = 60.4%；Luna 192/192 = 100.0%。分母排除初始 fixed 配方，仅计实际提案槽位。两种后端不能假定拥有相同的解码控制；Luna 的参数规模没有被此接口披露。

已完成不等于整个扩展研究完成

冻结快照中：K 实验 12/15 个任务-种子，跨源 6/9 个目标-种子，提案研究 8/30 个任务-种子-后端已完成并验证。DTI 与其余种子的未完成评价保留 N/A。主表 seeds 42-44 及四任务 racing seeds 53-55 已完成；新研究单独报告，不覆盖主表。

状态来自与英文附录 B 相同的已验证出版快照，并非实时队列或估计得分。

9 师姐批注如何落实

原 PDF 共 29 个标记，其中 24 条有文字意见；相邻空白高亮与便笺共同定位修改位置。以下按写作问题归并说明，逐项原文保留在批注记录中。

意见类型	这次修改	阅读位置
动机与定义太跳跃	先说明反复提案、实验和设计改进的需要；定义 client 为实验室计算 worker，再讲内外循环。	Introduction
computational changes 太抽象	具体到预测头、学习率、正则化和聚合设置；分别解释参数拟合与设计决策。	Introduction / Method
贡献不能泛称已有 harness	贡献聚焦历史证据打包、提案反馈和按学习轨迹分配验证预算；两类决策分开验证。	Method / Results 5.2
相关工作分类与引用	分 collaborative learning 与 AI for AI in bio 两部分；逐项核对引用，并区分任务模型与研究控制器。	Related work / 引用审计
方法层级与技术细节混杂	方法先给输入、模块、流程、输出和核心 loop；去掉步骤式正文，训练细节与 JSON schema 移至附录。	Method / Appendix A
主图存在不存在的数据、固定10和指标	集中式图只保留可用数据；框架用 K labs；任务示意不塞指标；统一语义配色与无交叉走线。	Figures 1-2
主表基线名不清楚	使用 Task model / Qwen direct，表注写明 TAPB、ProteinTalks-derived 与 scDEBART；生物预测来自任务模型。	Main table
效果表不知道检验什么	改为明确的问题：早期证据能否改善训练分配？列名 Uniform / Evidence-guided；DTI 开发回放移至附录。	Results 5.2
Discussion 与结尾冗长	归并为简洁 Conclusion；复现、伦理与 AI 使用声明分开；新增附录 B 明确已完成与 N/A。	Conclusion / Statements / B

修改后的叙述口径

积极陈述已经得到的结果，并把每个结果对应到实际实验。完整系统优势、固定候选训练分配收益、LLM 提案效率、来源迁移和执行可靠性分别讲清楚，不互相替代。

10 当前论文如何阅读

部分	核心内容
Abstract / Introduction	提出 collaborative biological research 问题，解释两层反馈与贡献。
Related Work	把 AIDE、AI Scientist、DrugEvolve、协作训练、FedEx、Helmsman 放入统一坐标。
Method	定义 task contract、proposal schema、inner trainer、evidence card 和 research history。
Experiments	明确五个端点、模型、划分、指标与六臂比较。
Results	5.1 完整系统；5.2 固定候选预算分配；5.3 实验室数、来源和搜索预算敏感性。
Conclusion	概括已验证贡献，并说明来源兼容性、分区与反馈泛化的研究方向。
Appendix A	完整 design library、proposal JSON、优化设置、六配置结果、次指标与不确定性。
Appendix B	K/跨来源/双后端的原始指标、有效提案率及明确的完成/待跑状态。

目前最强的论文信息

主比较已完整：同一套研究接口跨三个生物任务族完成训练与评价，完整系统领先所展示的五个端点中的四个。固定候选的同预算实验在 Norman 上给出 +10.84 点的正向证据。新的敏感性实验同时揭示了分区影响、负迁移以及开发选择不一定转化为测试增益；这些事实构成对机制的进一步分析。

当前写作已吸收师姐对逻辑、方法层级、模型名称、图示及段落结构的意见。尚未完成的实验不填估计分数，按附录 B 保留 N/A；整体投稿准备程度还取决于剩余实验、所有引用和最终全文核验。

复现 / 伦理 / AI 使用声明分别说明实验材料、数据本地边界及 AI 辅助范围。多机构真实部署仍需明确的安全与隐私方案；本研究没有新增受试者或湿实验。