

AI4AI4Cell 中文伴读版

协作式证据引导的生物模型改进

核心问题

多个生物实验室拥有互补数据。AI4AI4Cell 让这些数据在本地参与两件事：一是训练共享预测模型，二是为外层研究循环评价和选择下一版可执行设计。

DTI / 蛋白组学 / 细胞扰动	5	6 臂因子设计	42 / 43 / 44
蛋白组学 / 3 类细胞扰动	4	同预算 loop 隔离	53 / 54 / 55

对应英文稿：2026-09-22 当前统一实验版本

1 论文主线

一句话贡献

我们提出一个统一的协作研究框架：内层通过客户端本地训练更新模型参数，外层通过结构化 proposal、聚合开发证据和持续实验历史改进模型设计。


所谓 two levels 不是同一件事的两种说法，而是两个明确的反馈通道：

- 参数层：每个实验室在本地训练候选模型，协调器聚合更新，得到共享预测器。
- 设计层：每个实验室在本地开发集上评价候选模型，协调器形成 aggregate evidence card，决定保留哪一个设计，并把结果交给下一轮 proposer。

论文的三项贡献

协作研究框架	把 client-local parameter fitting 与 distributed design evaluation 连接起来。
新的 evidence-guided harness	统一 proposal schema、执行、保留规则和 accepted/rejected/failed 历史传递。
跨任务实证	用同一 core 在 DTI、蛋白组学和三类细胞扰动上做六臂、三 seed 对照。

2 三种研究范式



图中的颜色有固定语义：绿色表示实验室本地数据，蓝色表示预测模型，紫色表示研究 harness，橙色表示模型更新与证据聚合门。灰色虚线表示该范式缺少的模块。

Centralized bio-agent	在一份可访问数据上训练、评价并迭代设计	缺少多实验室聚合
Collaborative training	多实验室本地训练并聚合共享模型	可执行设计保持固定
AI4AI4Cell	同时更新共享模型与研究设计	aggregate evidence card 闭合外层循环

3 Harness 外层到底做什么

1. Hypothesize	任务契约、incumbent、历史 evidence cards	提出一个聚焦且可检验的假设
2. Instantiate	结构化 proposal	验证 design_id 并编译为可执行配置
3. Train + evaluate	候选设计、各实验室 train/dev shard	共享 predictor 与聚合开发诊断
4. Retain + remember	候选与 incumbent 的证据	保留较优设计；记录成功、拒绝与失败
5. Next proposal	完整有序研究历史	避免重复无效方向，并利用前轮结果形成下一假设

每个 proposal 的固定 JSON 字段

hypothesis	关于一个可编辑因素的明确预测
experiment	要执行的改变以及与 incumbent 的对照
expected_effect	预期指标方向和训练/验证诊断特征
design_id	可被机器解析并编译的候选标识

为什么历史记录重要

下一轮 loop 不只看到当前最好分数，还看到配置、best round、开发 metric/loss、首末训练诊断以及接受/拒绝/失败状态。因此实验历史是研究策略的状态，而不只是日志。

4 三个任务如何统一

DTI	compound + protein $\rightarrow$ interaction	TAPB + frozen ESM2 protein features	AUROC
Proteomics	observed 6h/24h proteome + drug $\rightarrow$ efficacy	ProteinTalks-derived efficacy head	AP
VCC	response + 5 single-gene options $\rightarrow$ identity	corrected scDEBART head	Macro Top-1
Norman	response + 5 double-gene options $\rightarrow$ identity	corrected scDEBART head	Macro Top-1
Tahoe	response + 5 drug options $\rightarrow$ identity	scDEBART + Morgan conditioning	Macro Top-1

一致性

五个端点共享同一个 inner trainer、proposal schema、evidence card、研究历史和 finalizer；任务差异只通过 adapter 和 scorer 进入。主实验使用 seeds 42 – 44；反馈隔离实验在四个可完整重训的端点上统一使用 seeds 53 – 55。

六臂因子设计

- 参与度：1 个实验室 vs 10 个实验室。
- 研究模式：fixed recipe vs feedback-free direct search vs feedback-guided loop。
- 因此可以分别计算 participation、design search 和 feedback 三种效应。

5 主结果

Fixed (1 lab)	82.83	25.05	29.94	25.56	19.40	36.55
Direct (1 lab)	89.89	20.13	21.09	14.15	15.42	32.14
AI4AI4Cell (10 labs)	93.76	36.99	31.54	22.25	22.39	41.39

所有数值都是 held-out 三 seed 均值乘以 100。AI4AI4Cell 在五个主端点中的四个最高，五端点描述性均值为 41.39。Norman 的最高值来自单实验室 fixed recipe。

整体结论

完整系统在分子互作、蛋白响应和细胞扰动三类任务上都取得了有竞争力的结果；相对于单实验室 direct optimization，五个端点分别变化 +3.87、+16.85、+10.45、+8.10 和 +6.97 个百分点。

6 Loop 是否真的有效

DTI (开发轨迹回放)	93.63	94.02	+0.39	2/1/0
Proteomics (留出)	37.47	37.47	+0.00	0/3/0
VCC (留出)	20.01	20.01	+0.00	0/3/0
Norman (留出)	11.48	22.32	+10.84	3/0/0
Tahoe (留出)	20.90	22.89	+1.99	1/2/0

- Direct 与 loop 使用相同的十个设计、十个实验室和 160 次开发评估。
- Direct 为每个设计平均分配 80 轮；loop 先为十个设计各训练 20 轮，再将剩余预算集中到六个由当前得分和学习趋势共同提升的设计；两者总计都是 800 个全客户端训练轮。
- 12 个新执行的留出 task-seed 对比为 4 胜、8 平、0 负。Norman 平均提升 10.84 点，95% CI 为 [4.54, 17.73]；Tahoe 平均提升 1.99 点，区间跨零。
- DTI 使用已有开发轨迹做保守回放：Direct 反而多 5 个 candidate-round，loop 仍为 2 胜、1 平；该行不作为新的留出结论。

Loop 的实证结论

证据历史不仅用于记录实验，还能成为预算分配的控制信号：在固定候选、数据、评估次数和训练预算后，它能保留 uniform search 的最优解，并在需要更长训练才能显现优势的设计上带来显著提升。

7 当前论文如何阅读

Abstract / Introduction	提出 collaborative biological research 问题，解释两层反馈与贡献。
Related Work	把 AIDE、AI Scientist、DrugEvolve、协作训练、FedEx、Helmsman 放入统一坐标。
Method	定义 task contract、proposal schema、inner trainer、evidence card 和 research history。
Experiments	明确五个端点、模型、划分、指标与六臂比较。
Results	主表回答完整系统水平；effect table 与 proposal-prefix 分析负责归因。
Appendix A	完整 design library、proposal JSON、15 条轨迹、六臂结果、次指标与不确定性。

目前最强的论文信息

同一套协作研究接口已经跨三个生物任务族完成训练、选择与 held-out 评价；完整系统在主表五个端点中的四个最高。进一步的同预算隔离实验得到 4 胜、8 平、0 负，并在 Norman 上取得 +10.84 点且置信区间为正的提升，证明 evidence-guided loop 可以实际改善计算预算的分配。

后续增强方向：独立实验室队列、client rotation、same-data centralized reference、更大的 compositional design space，以及 secure aggregation / differential privacy 部署层。