

AI4AI4Cell 中文伴读版

协作式证据引导的生物模型改进

核心问题

多个生物实验室拥有互补数据。AI4AI4Cell 让这些数据在本地参与两件事：一是训练共享预测模型，二是为外层研究循环评价和选择下一版可执行设计。

任务族	主端点	实验配置	随机种子
DTI / 蛋白组学 / 细胞扰动	5	六配置对照，已完成	42 / 43 / 44
蛋白组学 / 3 类细胞扰动	4	同预算训练分配，已完成	53 / 54 / 55
K / 独立来源 / 双后端	见附录 B	本轮实验矩阵已完成	DTI short:42；其余见表

对应英文稿：2026-09-23 已完成消融修订版

正文六节 + 附录 A/B；本文件用于快速伴读，不替代英文全文。

附录 B 同源快照 SHA-256: 1300ee2702358927...

1 论文主线

一句话贡献

我们提出一个统一的协作研究框架：内层通过客户端本地训练更新模型参数，外层通过结构化 proposal、聚合开发证据和持续实验历史改进模型设计。


所谓 two levels 不是同一件事的两种说法，而是两个明确的反馈通道：

- 参数层：每个实验室在本地训练候选模型，协调器聚合更新，得到共享预测器。
- 设计层：每个实验室在本地开发集上评价候选模型，协调器形成 aggregate evidence card，决定保留哪一个设计，并把结果交给下一轮 proposer。

论文的三项贡献

贡献	具体内容
协作研究框架	把 client-local parameter fitting 与 distributed design evaluation 连接起来。
证据引导的 loop 机制	把提案结果打包为可复用历史；把早期学习轨迹用于后续训练分配。这两类作用分别验证。
跨任务实证	共享训练与研究接口，并用匹配预算、参与度、来源和提案预算分析解释效果。


2 三种研究范式



绿色表示本地数据，蓝色表示预测模型，紫色表示研究 harness，橙色表示聚合与门控。K 是参与实验室数，不固定为 10。灰色虚线 harness 表示图中的固定设计配置，并非断言所有已有协作学习工作都没有 agent。集中式面板仅画实际可访问的数据源。

范式	具备的能力	关键差异
Centralized bio-agent	在一份可访问数据上训练、评价并迭代设计	缺少多实验室聚合
Collaborative training	多实验室本地训练并聚合共享模型	可执行设计保持固定
AI4AI4Cell	同时更新共享模型与研究设计	aggregate evidence card 闭合外层循环

3 架构总览



架构图使用用户提供的可编辑原图，仅修复字体与文字框排版，保留原文字。图中的 10 个实验室对应当前实验实例；一般方法使用 K 个参与实验室。

读图顺序

上方外层由研究模型提出、实例化、评价和修订设计；中部各实验室执行本地参数拟合，协调器聚合更新与开发诊断；下方显示三个任务族及输出。研究模型本身保持固定，反馈用于下一轮可执行设计。

3 Harness 外层到底做什么（续）

阶段	输入	输出 / 作用
1. Hypothesize	任务契约、incumbent、历史 evidence cards	提出一个聚焦且可检验的假设
2. Instantiate	结构化 proposal	验证 design_id 并编译为可执行配置
3. Train + evaluate	候选设计、各实验室 train/dev shard	共享 predictor 与聚合开发诊断
4. Retain + remember	候选与 incumbent 的证据	保留较优设计；记录成功、拒绝与失败
5. Next proposal	完整有序研究历史	利用前轮结果形成下一假设；是否有效由独立对照检验

每个 proposal 的固定 JSON 字段

字段	含义
hypothesis	关于一个可编辑因素的明确预测
experiment	要执行的改变以及与 incumbent 的对照
expected_effect	预期指标方向和训练/验证诊断特征
design_id	可被机器解析并编译的候选标识

为什么历史记录重要

下一轮 loop 不只看到当前最好分数，还看到配置、best round、开发 metric/loss、首末训练诊断以及接受/拒绝/失败状态。因此实验历史是研究策略的状态，而不只是日志。

Qwen direct 始终接收固定起始配方及未尝试的 design_id，不接收开发反馈；loop 接收当前保留配置和完整历史。二者的首个提案相同。

4 三个任务如何统一

任务	预测契约	任务参考模型	主指标
DTI	compound + protein → interaction	TAPB + frozen ESM2 protein features	AUROC
Proteomics	observed 6h/24h proteome + drug → efficacy	ProteinTalks-derived efficacy head	AP
VCC	response + 5 single-gene options → identity	corrected scDEBART head	Macro Top-1
Norman	response + 5 double-gene options → identity	corrected scDEBART head	Macro Top-1
Tahoe	response + 5 drug options → identity	scDEBART + Morgan conditioning	Macro Top-1

一致性

五个端点共享同一个 inner trainer、proposal schema、evidence card、研究历史和 finalizer；任务差异只通过 adapter 和 scorer 进入。主实验使用 seeds 42-44；固定候选预算分配实验在四个轻任务上使用 seeds 53-55；双后端提案反馈的单 seed 配置另列。

六配置因子对照

- 参与度：1 个实验室 vs 10 个实验室。
- 研究模式：fixed recipe vs feedback-free direct search vs feedback-guided loop。
- 主表比较完整系统；因子对照分别估计参与度、设计搜索和提案反馈的差异。

5 主结果

方法 / access	DTI	Protein	VCC	Norman	Tahoe	平均
Task model (1 lab)	82.83 $\pm$ 1.22	25.05 $\pm$ 4.56	29.94 $\pm$ 0.00	25.56 $\pm$ 0.00	19.40 $\pm$ 0.00	36.55 $\pm$ 0.82
Qwen direct (1 lab)	89.89 $\pm$ 1.02	20.13 $\pm$ 0.07	21.09 $\pm$ 4.38	14.15 $\pm$ 0.00	15.42 $\pm$ 6.21	32.14 $\pm$ 2.02
AI4AI4Cell (10 labs)	93.76 $\pm$ 1.11	36.99 $\pm$ 0.22	31.54 $\pm$ 0.08	22.25 $\pm$ 0.45	22.39 $\pm$ 2.59	41.39 $\pm$ 0.60

当前主表为已完成的 3 个 seed：held-out 均值 $\pm$ 样本标准差，均乘以 100。标准差反映固定数据划分上的训练／搜索波动，不是标准误或置信区间；总分分先按每个 seed 平均五项指标，再计算标准差。新增重复实验尚未计入。AI4AI4Cell 在五个主端点中的四个最高，五端点描述性均值为 41.39。Norman 的最高值来自单实验室 fixed recipe。

整体结论

完整系统在分子互作、蛋白响应和细胞扰动三类任务上都取得了有竞争力的结果；相对于单实验室 direct optimization，五个端点分别变化 +3.87、+16.85、+10.45、+8.10 和 +6.97 个百分点。

6 证据如何改进训练预算分配

先区分两个实验：主实验的 LLM 提案反馈决定下一次尝试什么设计；本页的固定候选 racing 则决定哪些设计值得继续训练。后者固定十个设计，不依赖 LLM 生成新设计。

端点	均匀分配	证据分配	增益	胜/平/负
Proteomics (留出)	37.47	37.47	+0.00	0/3/0
VCC (留出)	20.01	20.01	+0.00	0/3/0
Norman (留出)	11.48	22.32	+10.84	3/0/0
Tahoe (留出)	20.90	22.89	+1.99	1/2/0

- 均匀分配与证据分配使用相同的十个设计、十个实验室和 160 次开发评估。
- 均匀分配给每个设计 80 轮；证据分配先各训练 20 轮，按当前得分及上升趋势选出六个设计，从共同初始化重新训练 100 轮；两者总计都是 800 个全客户端训练轮。
- 12 个新执行的留出 task-seed 对比为 4 胜、8 平、0 负。Norman 平均提升 10.84 点，95% CI 为 [4.54, 17.73]；Tahoe 平均提升 1.99 点，区间跨零。
- DTI 仅有已有开发轨迹回放：均匀分配 525、证据分配 520 个 candidate-round，开发 AUROC 相差 +0.39 点（2 胜、1 平），单列于附录 A。

已经得到的机制结论

早期证据可以改善训练预算的分配，Norman 上三个种子均受益。它不等于 LLM 提案历史已经带来独立的最终分数增益：原六槽位主实验的 direct 与 loop 选中了相同终点；更大预算的提案研究见下一部分。

7 实验室数：参与度与分区分开看

五个端点都已完成 K=1、2、5、10 的两种设置。默认设计与 100 轮训练保持固定；DTI 为 seed 61，四个轻任务为 seeds 61-63 的均值 $\pm$ 样本标准差。分数均乘以 100。

参与度：增加实验室，也增加可用数据

使用原始十份分区中的前 K 份；这是更多实验室愿意参与时，实际获得更多训练数据的情景。

端点 / 指标	K=1	K=2	K=5	K=10
DTI / AUROC	83.65	84.43	89.62	93.88
PTPC / AP	26.03 $\pm$ 5.57	37.38 $\pm$ 0.60	29.63 $\pm$ 2.50	37.54 $\pm$ 0.27
VCC / Macro Top-1	30.02 $\pm$ 0.78	39.56 $\pm$ 0.11	31.88 $\pm$ 0.00	31.48 $\pm$ 0.16
Norman / Macro Top-1	25.56 $\pm$ 0.00	18.22 $\pm$ 0.00	19.68 $\pm$ 1.11	15.48 $\pm$ 0.00
Tahoe / Macro Top-1	19.40 $\pm$ 0.00	25.37 $\pm$ 0.00	20.90 $\pm$ 0.00	26.37 $\pm$ 0.86

固定全池：总数据相同，仅改变 K 个训练组

将全部目标训练数据重分为 K 组，保留原始十个开发面板等权评价。这里 K=1 使用全部数据，不是主表仅一份数据的单实验室。

端点 / 指标	K=1	K=2	K=5	K=10
DTI / AUROC	85.47	88.96	88.05	93.88
PTPC / AP	34.59 $\pm$ 5.66	37.36 $\pm$ 1.89	39.19 $\pm$ 0.43	37.54 $\pm$ 0.27
VCC / Macro Top-1	29.49 $\pm$ 0.00	28.80 $\pm$ 0.20	31.06 $\pm$ 0.22	31.48 $\pm$ 0.16
Norman / Macro Top-1	49.63 $\pm$ 4.20	19.56 $\pm$ 0.20	26.12 $\pm$ 0.11	15.48 $\pm$ 0.00
Tahoe / Macro Top-1	22.39 $\pm$ 0.00	21.39 $\pm$ 0.86	20.40 $\pm$ 0.86	26.37 $\pm$ 0.86

K 不是越大越好

Norman 固定全池 K=1 的均值为 49.63，K=10 为 15.48。分区改变本地优化以及细胞任务的对比学习负样本池；更多数据与更多训练分区是不同机制。因此需要同时保留两类 K 曲线。

8 不同来源的数据能否增益目标任务

DTI 使用 3 个独立来源，VCC 使用 3 项独立研究；蛋白组新增共享编码器 pilot 使用 Lin、Ruprecht 两项独立研究。所有来源条件及其组合均保留。分数为同一目标留出集的 AUROC (DTI)、macro Top-1 (VCC) 或 AP (PTPC)，均乘以 100。

目标	附加独立来源	分数	相对 target-only
DTI	Target only	85.47	+0.00
DTI	+ BioSNAP	82.44	-3.03
DTI	+ Davis	87.86	+2.39
DTI	+ Human	87.95	+2.48
DTI	+ All three	84.30	-1.18
VCC	Target only	29.49 ± 0.00	+0.00 ± 0.00
VCC	+ Replogle	27.12 ± 0.08	-2.37 ± 0.08
VCC	+ Nadig	26.94 ± 0.18	-2.55 ± 0.18
VCC	+ Jiang	33.07 ± 0.00	+3.58 ± 0.00
VCC	+ All three	27.33 ± 0.00	-2.15 ± 0.00
PTPC辅助	Target only	34.98	+0.00
PTPC辅助	+ Lin	35.01	+0.03
PTPC辅助	+ Ruprecht	35.50	+0.52
PTPC辅助	+ Both	35.31	+0.34

DTI: Davis / Human 为正向点估计，BioSNAP 与三源组合下降。VCC: Jiang 提升 3.58 点，但扰动簇 bootstrap 95% CI 为 [-2.11, 9.51]；三源合并下降 2.15 点。来源兼容性比简单堆叠来源更重要。

蛋白组：新增共享编码器及来源专属 head，保留目标原有十客户端，外源各为独立客户端；连续 viability / EC50 不改成目标二分类标签。只与同架构 target-only 配对。Ruprecht 提升 0.52 AP 点，药物簇 95% CI 为 [-1.46, 2.64]；四组两槽位 Luna pilot 的 loop-minus-fixed 均为 0。DTI / cell 跨源实验则把目标全池作为一个客户端。

同研究背景迁移另列：mtPTDS 的三个细胞背景不是三个独立研究。全部加入时 AP 从 34.59 ± 5.66 变为 35.47 ± 6.36；配对区间 [-2.44, 3.99]。decryptE 尚未参与训练，因此独立蛋白来源数仍为 2。

9 双后端短预算：五个端点已跑齐

同一原始 12 设计菜单、6 个提案槽位、每候选 100 轮。Direct 不接收开发反馈，loop 接收历史证据；双方均使用十个实验室。DTI 为 seed 42，其余四端点为 seed 61。这里是单 seed 机制实验，不替换主表三 seed 结果。

端点 / 后端	Fixed	Direct@6	Loop@6	Loop - Direct
DTI / Luna	94.27	94.60	94.27	-0.33
DTI / Qwen	94.27	94.27	94.27	+0.00
PTPC / Luna	37.27	37.27	37.27	+0.00
PTPC / Qwen	37.27	37.27	37.27	+0.00
VCC / Luna	31.50	31.50	31.50	+0.00
VCC / Qwen	31.50	31.50	31.50	+0.00
Norman / Luna	15.48	22.30	23.11	+0.81
Norman / Qwen	15.48	22.30	22.30	+0.00
Tahoe / Luna	25.37	26.87	26.87	+0.00
Tahoe / Qwen	25.37	25.37	25.37	+0.00

实验完成后的直接答案

十个成对终点为 1 项提升、1 项下降、8 项持平。Norman/Luna 提升 0.81 点，DTI/Luna 下降 0.33 点。该计数描述当前任务-后端单 seed 结果，不是显著性检验。

提案后端	有效槽位 / 总槽位	有效率
Qwen	55 / 60	91.7%
Luna	60 / 60	100.0%

有效率按快照重新计算，排除初始 fixed 配方，语法失败仍消耗提案槽位；它度量执行可靠性，不等价于预测质量。Luna 指实际使用的 gpt-5.6-luna API 后端，不推测未披露的参数规模。


预先记录 0、1、2、4、6 槽位前缀；完整前缀、开发轨迹和每次设计变更均在英文附录 B。DTI 的 20 个前缀分数已从相同 5,505 对测试样本的预测独立重算。

10 长预算：何时搜索有效，何时饱和

36 设计菜单、24 槽位、100 轮候选训练，四个轻任务 × 两后端均为 seed 61；DTI 未运行该协议。它与短预算的菜单不同，不能把二者当作只改变 loop 次数的直接消融。预算影响应看同一轨迹内的预设前缀。

端点 / 后端	Direct@24	Loop@24	共同开发目标 首次 D / L	有效槽位 D / L
PTPC / Luna	37.27	37.27	0 / 0	24 / 24
PTPC / Qwen	37.27	37.27	0 / 0	19 / 14
VCC / Luna	20.23	20.01	16 / 9	24 / 24
VCC / Qwen	19.61	19.61	18 / 23	11 / 16
Norman / Luna	23.11	23.11	22 / 4	24 / 24
Norman / Qwen	22.30	22.30	2 / 5	15 / 12
Tahoe / Luna	13.43	13.43	5 / 13	24 / 24
Tahoe / Qwen	13.43	13.43	18 / 14	14 / 15

最终留出结果为 0 项提升、1 项下降、7 项持平。Norman/Luna 的 loop 在第 4 槽达到共同开发目标，direct 第 22 槽才到，但最终均为 23.11；Tahoe/Luna 则是 direct 更快（5 对 13）。共同目标取双方最终开发主分数较小者，即双方均能达到的目标；更高终点的到达记录另存，不混比。



图左为 Norman、图右为 VCC 的开发轨迹，均保留 Qwen/Luna 的 direct/loop 四条曲线。另看完整留出前缀：VCC/Qwen 的测试 Top-1 从第 6 槽 31.50 降至第 24 槽 19.61；开发分数变好不必然带来最终测试提升。

有效提案：Qwen 116/192 = 60.4%；Luna 192/192 = 100.0%。曲线平台期只表示有限预算内不再改善，不是数学收敛；所有预设测试前缀均保留，不按测试高点截断。

11 完成范围与剩余工作

实验组	当前覆盖	可以回答的问题
主表与六臂对照	5 端点, seeds 42-44, 完成	完整系统、参与度和设计搜索
固定候选预算分配	4 轻任务, seeds 53-55, 完成	早期轨迹如何分配同等训练预算
双后端短预算	5 端点 × Qwen/Luna, 10 对, 完成	六槽位内提案反馈的独立影响
双后端长预算	4 轻任务 × Qwen/Luna, 8 对, 完成	有限预算搜索动态; 不含 DTI
实验室 K 两种设置	5 端点 × 4 档 × 2 设置, 完成	更多数据与固定数据分区的差异
DTI / cell 独立来源	DTI 3 源; VCC 3 源, 完成	目标数据不变时外部研究的影响
Protein 独立来源 pilot	Lin、Ruprecht 两源, 完成	新共享编码器上的匹配来源迁移
未计入本次完成范围	第三蛋白源 decryptE 未训练; DTI long24 未做 ; 更多 seed 待扩展	不填估计值, 不计为独立重复

论文中三种不同的证据

完整系统结果回答整体工作流是否有用; 固定候选 racing 回答证据是否改善算力分配; 双后端 short6 / long24 回答 LLM 提案历史是否带来更好的搜索或终点。Norman 的 +10.84 点属于固定候选预算分配对照, 不能移作提案反馈在所有任务均有效的结论。

本轮定义好的可运行实验矩阵已经完成并复核。更多 seed、DTI 长预算和第三蛋白源属于扩展范围; “完成矩阵”不意味着已经获得所有场景一致的 loop 增益, 或所有外源组合的正迁移。

本稿所有新增表均来自与英文附录 B 相同的 completed_ablation 出版快照; 与原主实验分开报告, 不混合不同任务指标、模型架构或候选菜单计算新的平均优势。

12 师姐批注如何落实

原 PDF 共 29 个标记，其中 24 条有文字意见；相邻空白高亮与便笺共同定位修改位置。以下按写作问题归并说明，逐项原文保留在批注记录中。

意见类型	这次修改	阅读位置
动机与定义太跳跃	先说明反复提案、实验和设计改进的需要；定义 client 为实验室计算 worker，再讲内外循环。	Introduction
computational changes 太抽象	具体到预测头、学习率、正则化和聚合设置；分别解释参数拟合与设计决策。	Introduction / Method
贡献不能泛称已有 harness	贡献聚焦历史证据打包、提案反馈和按学习轨迹分配验证预算；两类决策分开验证。	Method / Results 5.2
相关工作分类与引用	分 collaborative learning 与 AI for AI in bio 两部分；逐项核对引用，并区分任务模型与研究控制器。	Related work / 引用审计
方法层级与技术细节混杂	方法先给输入、模块、流程、输出和核心 loop；去掉步骤式正文，训练细节与 JSON schema 移至附录。	Method / Appendix A
主图存在不存在的数据、固定10和指标	范式图只保留实际可用数据；方法图使用用户提供的可编辑架构图，保留原文字，图注说明实验的10对应一般K。	Figures 1-2
主表基线名不清楚	使用 Task model / Qwen direct，表注明 TAPB、ProteinTalks-derived 与 scDEBART；生物预测来自任务模型。	Main table
效果表不知道检验什么	改为明确的问题：早期证据能否改善训练分配？列名 Uniform / Evidence-guided；DTI 开发回放移至附录。	Results 5.2
Discussion 与结尾冗长	归并为简洁 Conclusion；复现、伦理与 AI 使用声明分开；附录 B 更新已完成的K、独立来源、双后端及预算分析。	Conclusion / Statements / B

修改后的叙述口径

积极陈述已经得到的结果，并把每个结果对应到实际实验。完整系统优势、固定候选训练分配收益、LLM 提案效率、来源迁移和执行可靠性分别讲清楚，不互相替代。

13 当前论文如何阅读

部分	核心内容
Abstract / Introduction	提出 collaborative biological research 问题，解释两层反馈与贡献。
Related Work	把 AIDE、AI Scientist、DrugEvolve、协作训练、FedEx、Helmsman 放入统一坐标。
Method	定义 task contract、proposal schema、inner trainer、evidence card 和 research history。
Experiments	明确五个端点、模型、划分、指标与六臂比较。
Results	5.1 完整系统；5.2 固定候选预算分配；5.3 实验室数与独立来源；5.4 研究模型与搜索预算。
Conclusion	概括已验证贡献，并说明来源兼容性、分区与反馈泛化的研究方向。
Appendix A	完整 design library、proposal JSON、优化设置、六配置结果、次指标与不确定性。
Appendix B	已完成 K、独立来源、双后端短/长预算、全部前缀曲线、设计变更与有效提案率。

目前最强的论文信息

主比较已完整：同一套研究接口跨三个生物任务族完成训练与评价，完整系统领先所展示的五个端点中的四个。固定候选的同预算实验在 Norman 上给出 +10.84 点的正向证据。新的敏感性实验同时揭示了分区影响、负迁移以及开发选择不一定转化为测试增益；这些事实构成对机制的进一步分析。

当前写作已吸收师姐对逻辑、方法层级、模型名称、图示及段落结构的意见。本轮可运行消融矩阵已经完成；更多 seed、DTI long24 与第三独立蛋白源未计入完成范围。投稿前仍需共同确认贡献表述、来源迁移的统计精度，以及单 seed 提案反馈结果的解释。

复现 / 伦理 / AI 使用声明分别说明实验材料、数据本地边界及 AI 辅助范围。多机构真实部署仍需明确的安全与隐私方案；本研究没有新增受试者或湿实验。